

PLD-Comp

Développement d'une chaîne complète de compilation

Dans ce projet, nous allons concevoir un compilateur pour un sous-ensemble du langage C (voir sujet ci-dessous) grâce à Antlr4 et l'utilisation du langage C++.

1 Le langage

Il s'agit d'un sous-ensemble du langage C avec les éléments suivants :

- Types de données : restriction aux types `char`, `int32_t` et `int64_t`
- Initialisation d'une variable possible lors de sa déclaration
- Tableaux à une dimension
- Définition de fonctions. Les procédures (qui n'ont pas de type de retour) devront utiliser le type retour `void`.
- Structures de contrôle : `if`, `else`, `while`
- Structure de blocs grâce à `{` et `}`
- Expressions : tous les opérateurs du langage C y compris l'affectation. Il conviendra de faire dans un premier temps les opérateurs primordiaux pour construire des programmes (comparaisons et opérations arithmétiques) puis ensuite de diversifier.
- Déclaration de variables seulement au début des fonctions (et donc pas à l'intérieur)
- Possibilité de déclarer des variables globales
- Utilisation des fonctions standard `putchar` et `getchar` pour les entrées-sorties
- Constante caractère (avec la simple quote)
- Les chaînes de caractères pourront être représentées par des tableaux de `char` (pas de constantes chaînes de caractères)
- Un seul fichier source sans pré-processing (pas d'inclusions externes ni macros, toutefois les directives du pré-processeur devront être autorisées mais ignorées afin de garantir que la compilation par un autre compilateur soit possible. Exemple : inclusion de `stdint.h`)

Exemple de programme :

```
#include <stdint.h>

void main(void) {
    int32_t a;
    int32_t b;
    a=0;
    b=6;
    if (a*5+3*b==18)
    {
        putchar('o');
        putchar('k');
    }
}
```

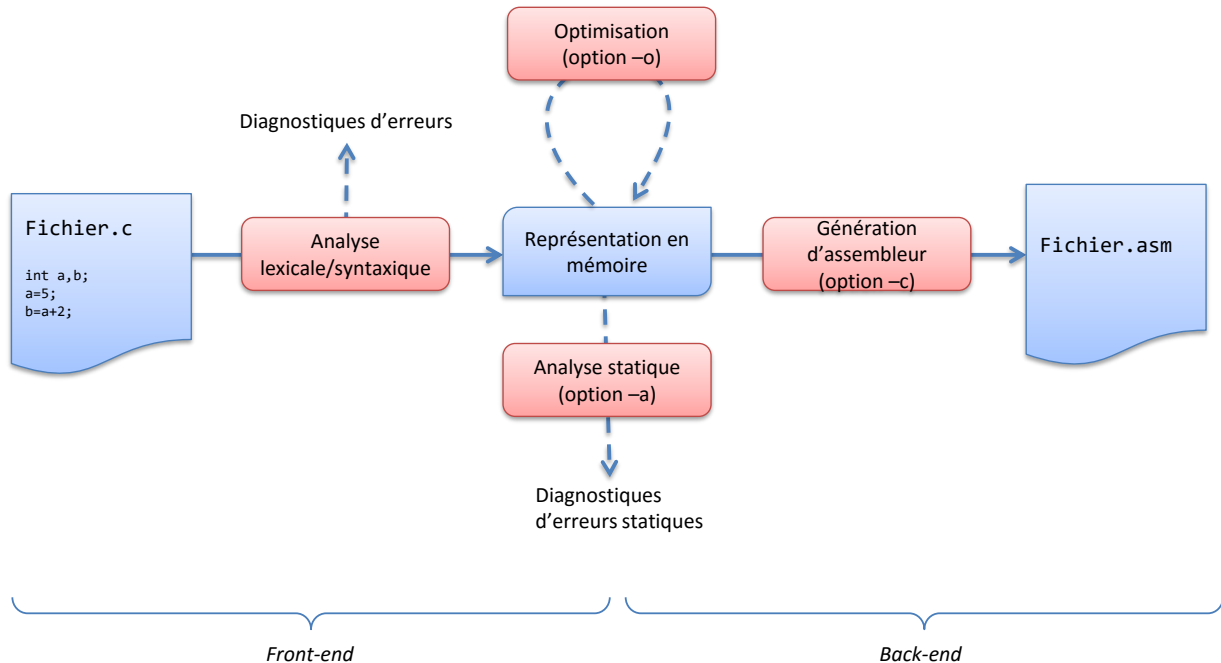
Plus particulièrement le langage qui devra être analysé **ne comprend pas les éléments suivants** :

- Pointeurs (toutefois, on pourra utiliser la notation `[]` comme argument d'une fonction pour passer en paramètre un tableau par son adresse)
- La possibilité de séparer dans des fichiers séparés les déclarations et les définitions

- La structure de contrôle `switch..case`
- La structure de contrôle `for`
- La structure de contrôle `do..while`

2 Architecture globale de l'outil

Voici le schéma de l'architecture globale de l'outil :



Le logiciel se présente sous la forme d'un outil en ligne de commande dont l'argument principal est le nom du fichier à analyser. Par défaut, l'outil va analyser le fichier, en faire une représentation en mémoire et afficher des diagnostics d'erreurs (lexicales, syntaxiques ou sémantiques simples). Chaque erreur devra faire apparaître le numéro de ligne et de manière optionnelle le numéro de colonne dans le fichier source. En complément, il existe trois options en ligne de commande qui permettent d'enrichir ce fonctionnement de base :

1. Analyse statique du programme (option -a). Cette option fait une analyse du programme de manière statique afin d'en extraire des erreurs (sur la sortie d'erreur standard).
2. Transformation du programme afin de le simplifier (option -o). En propageant les constantes et en simplifiant certaines expressions (éléments neutres), la représentation interne du programme est modifiée.
3. Génération de code (option -c). Cette option permet de générer le code assembleur dans un fichier séparé.

3 Étapes de travail

Les étapes sont ici données à titre indicatif, organisez vous comme vous le souhaitez. Certaines étapes sont parallélisables, à vous de les détecter. On peut par exemple très bien construire à la main une représentation d'un programme en faisant appel aux constructeurs (donc sans analyse syntaxique ni lexicale). Cela permet de tester certaines fonctionnalités avant l'intégration.

Écriture de la grammaire. Reprenez les éléments du langage exprimés dans la première section et déduisez-en une grammaire. Gardez en vue que vous devrez implémenter cette grammaire dans Antlr4 donc qu'il faut le plus possible être adapté à une analyse descendante. Les grammaires Antlr4 autorisent de mettre des répétitions de symboles ou de parties de règles, profitez de cette possibilité pour ne pas utiliser de règle récursive lorsque cela est possible.

Identification des expressions régulières. Pour chacun des éléments du langage (symboles terminaux), identifiez les expressions régulières associées. Si cela est nécessaire (expressions régulières ayant des éléments communs).

Conception des structures de données. Il s'agit ici de définir les structures qui contiennent le programme lui-même (arbre syntaxique abstrait) et les différents dictionnaires nécessaires (table des symboles, etc).

On demande un diagramme de classes UML.

Vous êtes invités à faire valider cette modélisation par l'équipe enseignante dans le but de ne pas perdre de temps.

Implémentation de l'analyseur avec Antlr4. À partir de la grammaire et des expressions régulières identifiées précédemment, produisez le fichiers Antlr4 de la grammaire (extension `.g4`) qui permettent d'analyser le code source afin d'en valider la construction grammaticale. Cette phase n'est qu'une transcription de votre grammaire. Si la grammaire est bien conçue, ce sera une formalité. N'oubliez pas qu'avec Antlr4, les règles les plus prioritaires doivent apparaître en premier. Les règles devront être nommées afin de générer des visiteurs dans la partie suivante.

Construction de la représentation en mémoire. Dérivez un visiteur de votre arbre syntaxique abstrait de celui fabriqué par Antlr4 de manière automatique. Chaque visite de noeud devra donc renvoyer un type bien précis vers une de vos structures de données.

Résolution de portée de variables. Dans une expression, lorsqu'une variable est utilisée, on ne connaît que son nom. Le but de cette partie est de faire le lien entre les variables utilisées et leurs déclarations. Attention, il y a plusieurs types de variables dont l'emplacement mémoire sera différent au moment de la génération de code assembleur. Par exemple une variable de fonction n'est pas au même endroit qu'une variable globale ou qu'un paramètre de fonction. À l'issue de cette partie, toutes les ambiguïtés sont levées (par exemple, une variable de fonction qui masque un paramètre de fonction, ou une variable globale). Vous serez à même de détecter dans cette partie l'utilisation de variables non déclarées.

Vérification statique du programme. Réfléchissez à l'algorithme qui va permettre de vérifier la validité du programme de manière statique. Voici les éléments qui sont vérifiables dans cette partie :

- Une variable est utilisée (en partie droite d'une affectation ou dans une opération d'écriture) sans avoir jamais été affectée.
- Une variable a été déclarée et jamais affectée ou utilisée.

Typage des noeuds intermédiaires. Il s'agit dans cette partie de donner à chaque noeud intermédiaire d'expression un type en fonction du type de ses opérandes. Cela dépend de l'opérateur aussi. Exemple, une addition ne sera pas traitée pareil qu'une affectation.

À la moitié du projet (4 séances), vous devriez avoir terminé toutes les tâches précédentes, et donc avoir le *front-end* opérationnel. Vous pouvez maintenant passer au *back-end*.

Définition des structures de données pour une représentation intermédiaire linéaire. Il s'agit de définir une structure de donnée qui reste abstraite mais se rapproche de l'assembleur. Ce sera un un graphe orienté d'instructions élémentaires à trois adresses (deux variables opérandes, une variable destination). Dans ce graphe, la plupart des instructions élémentaires n'ont qu'un successeur, seul le saut conditionnel a deux successeurs possibles. Les dictionnaires seront partagés avec l'AST.

Transformation de l'AST vers la représentation linéaire. Le travail ici consiste à "désucrer" le code initial :

- démonter les expressions en séquences de code trois adresse
- démonter les `for`, `while` et `if` en sauts conditionnels
- mettre toutes les variables à plat dans une seule portée

Ceci se fait par un parcours de l'AST. Dans ce processus, on créera autant de variables intermédiaires que nécessaire.

Génération de code assembleur à partir de la représentation linéaire. On produira dans cette partie de l'assembleur, a priori pour un processeur de PC (x86 64-bits), mais l'une des cibles suivantes sera la bienvenue :

- assembleur ARM (par exemple pour Raspberry Pi)
- assembleur MSP430
- java bytecode (sans utiliser le modèle objet)

On demande de l'assembleur sous forme textuelle qui sera assemblé en code machine par `as`. Vous avez donc droit aux *labels* et autres facilités offertes par GNU `as`. On ne demande pas d'allocation de registre ici.

Gestion des appels de procédures. Pour les programmes qui ont plusieurs procédures, il faudra gérer la pile des appels, sur laquelle seront placées toutes les variables locales de chaque procédure.

Outil en ligne de commande - intégration. Il s'agit là de concevoir et implémenter l'outil qui va permettre d'interfacer l'analyseur.

Optimisations (facultatif mais recommandé). Certaines optimisations peuvent se faire sur l'AST :

- propagation de constantes : une expression dont toutes les opérandes sont des constantes sera remplacée par la valeur résultante.
- éléments neutres : pour chaque opérateur qui possède un élément neutre (l'addition le 0, la multiplication le 1, *etc.*), les opérations correspondantes peuvent être supprimées lorsqu'elles surviennent.

Certaines optimisations se font sur la représentation linéaire :

- destruction des instructions redondantes (optimisation à fenêtre)
- calcul de vivacité des variables et allocation des registres

Et voici une extension/optimisation qui touche à la fois *front-end* et *back-end* : le support du `switch/case` du langage C, implémenté par une table de sauts. C'est une optimisation car, sur des gros `switch`, la table des sauts va bien plus vite que des `if` imbriqués.

4 Livrables (zéro papier)

Le projet se déroulera en deux temps avec un document de conception à mi-parcours à déposer sur moodle qui reprendra les éléments suivants :

- la grammaire du langage que vous avez utilisée
- la description des structures de données sous forme d'un diagramme de classes
- la liste des fonctionnalités implémentées

À l'issue du projet, un livrable de réalisation sera déposé sur moodle. Ce dossier de réalisation (application testable sur les machines LINUX du département) sera déposé sur moodle sous la forme d'une archive zip¹. Merci de nettoyer l'archive pour ne pas qu'elle contienne des binaires ni des répertoires cachés. Le zip contiendra :

- tous les sources de votre application
- le `makefile` avec une cible par défaut qui crée l'exécutable et une cible « test » qui lance les jeux de tests
- vos jeux de tests

Enfin, une présentation orale montrera l'état de l'avancement du projet et l'exécution commentée des tests dans divers cas à l'issue du projet (pendant les deux dernières heures de la dernière séance).

5 Phasage recommandé pour le back-end


On peut distinguer en gros trois tâches parallèles :

- Tâche 1 : Définir l'IR et transformer l'AST en IR
- Tâche 2 : Transformer l'IR en assembleur x86
- Tâche 3 : Optimiser l'IR

On va ignorer la tâche 3 tant que le compilateur n'est pas complètement opérationnel.

Et on va essayer de développer les tâches 1 et 2 en parallèle pour que votre compilateur soit toujours opérationnel de bout en bout, mais sur des programmes de plus en plus compliqués.

Le graphe de dépendances des différentes sous-tâches est le suivant (en utilisant les numéros des sections) :



Les sous-tâches obligatoires vont jusqu'à 5.13. Le chemin à explorer en priorité est le chemin du haut, qui vous emmène jusqu'à la boucle while en 5.7. En gros il est recommandé de suivre l'ordre du sujet... Les autres chemins correspondent aux appels récursifs de fonctions (5.8), à l'implémentation des accès aux tableaux (5.9 et 5.10), et aux boucles for (5.12) dans cet ordre de priorité.

Validez chaque section auprès d'un enseignant. Les programmes de validations sont dans le répertoire `TestCPrograms/Back/`. Vous êtes encouragés à les modifier.

1. ce format d'archive permettra d'éviter d'encoder les droits d'accès sur les fichiers comme le ferait une archive tgz

5.1 Générer un squelette vide

Vous trouverez dans le répertoire 1-Minimal-Skeleton un fichier assembleur `main.s` et un script qui l'assemble et le linke avec la `glibc`.

Votre compilateur doit produire `main.s`, puis l'assembler comme le montre ce script.

- Lancez ce script.
- Modifiez `main.s` et observez que ce changement est pris en compte.
- Mettez en place un squelette de compilateur qui produit (en gros) ce squelette.

Le programme qui doit valider cette étape :

```
void main() {  
}
```

5.2 Comprendre l'enregistrement d'activation et l'ABI

Allez lire la section B en détail et faites les expériences décrites.

Du boulot pour la tâche 2 :

- écrivez une fonction `gen_prologue` qui prend un nom de fonction et une taille d'AR à réserver.
- écrivez une fonction `gen_epilogue`.

Il y aura du boulot pour T1 aussi : il devra calculer quelle est la taille de l'AR à réserver. Dans un premier temps, on va y mettre toutes les variables locales, d'entrée et de retour :

- associez à chaque variable, dans votre table des symboles, un index dans l'AR. Remarque : les paramètres sont fâcheux puisqu'ils sont dans des registres. La solution la plus simple est que le prologue les copie vers des variables locales, après quoi ils auront un index comme tout le monde.
- une fois ceci fait vous connaissez la taille totale (à passer à `gen_prologue`)

Dans un premier temps vous êtes très fortement encouragés à ne manipuler que des index multiples de 8 octets quitte à perdre de la place dans votre AR. Autrement dit, donnez 8 octets à chaque char et à chaque `int32`. Dans un second temps, vous pourrez optimiser l'allocation de vos différentes variables locales dans l'AR. L'ABI n'impose rien à ce sujet, mais l'ISA impose que les variables 64bits aient des adresses multiples de 8 et les variables 32 bits des adresses multiples de 4. **En particulier `rsp` et `rbp` doivent toujours être des multiples de 8.**

Validez votre prologue et votre épilogue sur le programme suivant, qui devra bien laisser la pile dans l'état où il l'a trouvée.

```
#include<inttypes.h>  
void toto() {  
    int64_t x;  
    int64_t y;  
    int64_t z;  
}
```

5.3 Compiler un programme qui fait un `putchar()`

Le but de cette étape est de compiler

```
#include<inttypes.h>  
void main(void) {  
    putchar('O');  
    putchar('K');  
    putchar(' ');  
}
```

Il faut avouer que c'est une marche assez haute, mais une fois ceci fait on aura les appels de fonctions.

Commencez par relire le chapitre *Compiling the body* du poly : tout y est.

La génération de code pour une constante est un cas particulier de génération de code pour une expression : mettez en place les squelettes de méthodes `genIR(CFG* cfg)` sur votre AST.

Pour compiler la constante, il faut créer une nouvelle variable temporaire dans la table des symboles : on accède à cette table des symboles par le CFG passé en paramètre.

Ensuite, le code IR est juste constitué d'une seule instruction, et le `genAsm()` pour ce code produit aussi une seule instruction (voir le poly III.1.1 et III.3.2).

L'appel de fonction peut générer pas mal de code (mais pas dans notre exemple).

- `CallExpr::genIR` doit évaluer la valeur de chaque expression passée en paramètre et se souvenir des variables dans lesquelles il les a rangées. Puis il doit émettre une seule instruction IR `call` qui prend en paramètre cette liste de variables.
- `genAsm()` émet l'assembleur qui recopie chaque variable dans un registre suivant la section B. Puis il émet une instruction x86 `call`.

Mais ici pour commencer, on peut ne gérer que les appels de fonction à un argument et ignorer la valeur retournée (à réparer respectivement en 5.11 et 5.8).

Quand vous avez réussi à passer cette étape, le reste devrait aller plus vite et être plus intéressant.

5.4 Compiler l'affectation vers une variable

L'étape suivante est d'arriver à compiler le programme suivant :

```
void main(void) {  
    char a, b, c;  
    a='O';  
    b=a;  
    c='K';  
    a='\n';  
    putchar(b);  
    putchar(c);  
    putchar(a);  
}
```

Voir le poly pour vous rafraîchir sur le code à générer pour les parties droites et gauche du `=`. Dans un premier temps, vous ne gérerez pas les lvalues générales. La génération d'IR pour le nœud affectation se contentera de vérifier que la lvalue est une variable simple (et produira une erreur sinon). Le code IR à émettre sera donc juste une copie, comme dans le poly *'Simple assignment code when the lvalue is a scalar variable'*.

Le travail commun à T1 et T2 est de mettre en place la structure de donnée pour l'IR. Dans un premier temps on pourra se contenter de développer le bloc de base (BB), qui correspond à du code linéaire, sans test ni branchement. Le graphe de contrôle de flot (qui est un graphe de BB) devra être mis en place à partir de la section 5.6.

5.5 Compiler des expressions

Sur le fond c'est un parcours d'arbre, voir le poly. La nouveauté est que ce parcours peut créer des variables temporaires pour les calcul intermédiaires. Ajoutez les dans votre table des symboles à la suite de vos variables locales.

Quand vous arriverez à compiler le programme suivant vous aurez fait le plus dur :

```
void main(void) {
```

```
char a;  
char b;  
char c;  
a='M';  
b=1+a+1;  
c=b+1;  
putchar(b);  
putchar(c);  
putchar('\n');  
}
```

5.6 Compiler le `if ... else`

A partir de là il faut créer des blocs de base, donc gérer les successeurs d'un BB. Il est conseillé d'avoir deux BB spéciaux : le point d'entrée de la fonction (il devra générer le prologue) et un point de sortie unique qui générera l'épilogue.

```
void main(void) {  
    if (1<2) {  
        putchar('V');  
    }  
    else {  
        putchar('F');  
    }  
    putchar('\n');  
}
```

Modifiez tout de même ce programme pour vérifier que vous pouvez tester la valeur d'une variable.

5.7 Compiler les boucles `while`

À la surprise générale, si une fois que le `if-then-else` marche, le `while` vous prendra quelques minutes à faire tomber en marche, car il ne demande rien en plus.

```
#include<inttypes.h>  
void main(void) {  
    int64_t i;  
    i=0;  
  
    while(i<5) {  
        putchar('V');  
        i=i+1;  
    }  
    putchar('\n');  
}
```

5.8 Compiler le retour de valeur

Il faut réfléchir au cas où il y a plusieurs `return expr;` dans un programme. Définissez une variable temporaire spéciale `retvalue`.

`return expr;` évalue `expr`, copie le résultat dans `retvalue`, puis saute au BB de sortie.

La génération d'assembleur pour ce BB de sortie copie le contenu de `retvalue` dans `%rax`, puis émet l'épilogue.

Validation sur une fonction récursive qui calcule la factorielle.

5.9 Compiler l'affectation à une lvalue quelconque

Ici il faut mettre en place l'affectation à une lvalue quelconque. Débranchez (temporairement) le test suggéré en 5.4, puis implémentez l'usine à gaz décrite dans le poly, section *Generic Lvalue-based assignment code*. Testez que cela marche sur des programmes qui ne font que des affectations dans des variables (et marchaient jusque là).

5.10 Compiler des tableaux

Rien de bien méchant si vous avez compris 1/ la distinction entre lvalue et rvalue et 2/ que `a[i]` c'est du sucre syntaxique pour

`Mem[a+i*sizeof(type(a))]`.

5.11 Compiler les appels de fonction ayant jusqu'à 6 arguments

Les registres à utiliser sont décrits dans l'ABI.

5.12 Compiler les boucles **for**

Rien de bien méchant si vous connaissez la sémantique.

5.13 Test sur des programmes complexes

A ce stade votre compilateur doit être capable de compiler une factorielle récursive, la suite de Syracuse et la fonction d'Ackermann.

5.14 Gestion correcte des types

Essayez de ne consommer dans votre AR qu'un octet pour les chars, et 4 pour les int32. Vous avez le droit de regrouper tous les chars d'un programme ensemble et tous les int32 d'un programme ensemble.

Attention, cela ne marchera que si votre génération d'instruction gère également les types : il faut utiliser des `movb`, `movl`, `movq` à bon escient et avec les bons noms de registres (par exemple `%eax` pour 32 bits et `%al` pour 8 bits). En effet une lecture de la mémoire vers `%rax` n'est légale que si l'adresse est un multiple de 8.

Pour valider cette étape, vérifiez que vos prologue et épilogue sont corrects sur des variations du programme suivant :

Remarque si vous êtes en avance et que vous voulez produire un compilateur recible : Ces contraintes d'alignement dépendent du processeur cible. Par exemple sur MSP430 les variables 32 bits doivent juste être alignées sur des adresses paires. Les contraintes d'alignement doivent donc être fournies par la classe processeur qui encapsule toute la transformation d'IR en assembleur.

5.15 Compiler les appels de fonction ayant plus de 6 arguments

Les arguments supplémentaires doivent être empilés par l'appelant, et utilisés par l'appelé. Là il y a quelque chose d'intéressant et nouveau, c'est qu'il faut utiliser des offsets positifs pour aller piocher les paramètres empilés.

Exercice : trouver dans l'ABI qui fait le dépilement des paramètres ainsi passés, l'appelé ou l'appelant ?

Attention cependant, grosse difficulté pratique si vous voulez respecter l'ABI : il faut 1/ gérer les types proprement, et 2/ empiler les paramètres comme spécifié par l'ABI.

A Spécification de la représentation intermédiaire

L'IR est à mi-chemin entre le C et un assembleur.

Ce qui ressemble à de l'assembleur :

- L'IR ne connaît que les types de base (int64, int32, int8). En particulier les adresses sont des entiers (int64 sur notre cible 64-bits), et les accès aux tableaux ont été transformés en calculs sur les adresses.
- Il y a une variable particulière `!bp` qui contient le pointeur de base (`%rbp` sur notre cible). Les adresses des variables locales et paramètres sont définies par un offset relatif à ce `!bp`.
- L'IR ne connaît que des instructions à 1 ou 2 opérandes (sauf le `call`)

Ce qui ressemble à du C :

- L'IR travaille avec un nombre arbitraire de variables : outre le pointeur de base `!bp`, on a toutes les variables du programme, et des variables temporaires `!tmp1` jusqu'à `!tmp∞`. On peut demander, lors de la construction de l'IR, la création d'une nouvelle variable temporaire.
- Dans un premier temps, toutes ces variables seront mappées vers autant de nouveaux symboles dans la table des symboles (et donc autant de cases mémoires dans l'enregistrement d'activation)². C'est pour les différencier des variables C (qui vivent aussi dans la table des symboles) que les noms des temporaires créés par le compilateur commencent par un `!` : cela évite les conflits de nom avec des variables C. Si j'avais mis un `%` vous auriez été capables de confondre avec les registres du Pentium.
- L'instruction `call` a un nombre arbitraire de paramètres, mais ces paramètres sont tous des variables simples (pas d'expression).

Ce qui ne ressemble à rien du tout : le graphe de flot de contrôle.

- Les instructions d'une fonction sont groupées en séquences linéaires appelées *basic block* ou BB. Dans un BB, toutes les instructions s'exécutent en séquence.
- Le CFG d'une fonction se compose d'un BB d'entrée (il générera le prologue), d'un BB de sortie (il générera l'épilogue), et d'un nombre quelconque de BBs intermédiaires.
- Un BB commence par une étiquette (une destination de saut) et termine
 - par un saut à un autre BB,
 - ou par deux sauts choisis en fonction du résultat d'un test,
 - ou par le retour de la fonction si c'est le BB de sortie.
- Il n'y a pas d'instruction de saut dans l'IR : toute l'information de branchement est encodée dans les successeurs d'un BB.

A.1 Jeu d'instructions

Voici le jeu d'instruction minimal à utiliser.

Mnémonique	Description
<code>var <- const</code>	met une constante dans une variable
<code>var <- var1+var2</code>	opération binaire (aussi <code>+</code> , <code>-</code> , <code>*</code> , ainsi que les comparaisons <code><</code> , <code><=</code> , <code>></code> , <code>>=</code> , <code>=</code>)
<code>var <- call label (var1, var2, var3...)</code>	appel de sous-routine
<code>var1 <- (var2)</code>	lecture mémoire : le contenu de la case d'adresse <code>var2</code> est placé dans <code>var1</code>
<code>(var1) <- var2</code>	écriture mémoire.

2. Et dans les exemples du poly, le numéro d'une temporaire est son offset dans l'AR, ce qui facilite légèrement le débogage.

Vous avez remarqué que les résultats des comparaisons sont dans des variables, pas dans des drapeaux comme sur un vrai processeur.

Il n'y a pas d'instruction de branchement. Les branchements sont encodés dans le graphe de BasicBlocks :

- Un BB avec deux successeurs génère un saut conditionnel vers le second successeur, puis un saut inconditionnel vers le premier. La valeur booléenne qui décide le saut est la dernière valeur calculée du BB. Souvent, ce sera une instruction `cmp`.
- Un BB avec un successeur génère juste le saut inconditionnel
- (le BB sans successeur génère l'épilogue de la fonction)

Un problème est que la plupart des vrais processeurs marchent avec des drapeaux. Voici une manière simple de gérer ceci :

- Tous les BB génèrent le saut inconditionnel après avoir généré le code pour leurs instructions.
- La génération de code pour une instruction de comparaison, *si cette instruction est la dernière de son BB*, génère une instruction assembleur de comparaison puis le saut conditionnel vers la branche false. Sinon, une instruction de comparaison génère du code comme les autres opérations binaires.
- Un BB qui a deux successeurs et ne finit pas par un `cmp` doit générer le code x86 qui teste la valeur booléenne de la variable retournée par la dernière instruction, et implémente les deux sauts conditionnels correspondant.

A.2 Remarques sur les choix faits

Dans le Cooper et Torczon,

- l'IR n'a pas de `call`, c'est glissé sous le tapis.
- l'IR a des sauts conditionnels
- l'IR aussi des opérations binaires avec une constante en place de `reg2`, et un adressage indexé par une constante.

Restons sur une IR minimale : c'est une optimisation à implémenter ensuite de fusionner plusieurs instructions IR en une vraie instruction assembleur complexe.

A.3 La classe `IRInstr`

... a comme attributs et méthodes

- un mnémonique du tableau ci-dessus,
- ses paramètres (les `reg`, `const` et `label` du tableau),
- un pointeur vers le CFG qui la contient (qui fournira entre autres la table des symboles),
- une méthode de génération d'assembleur.

A.4 La classe `BasicBlock`

... a comme attributs et méthodes

- une séquence de `IRInstr`,
- un pointeur, éventuellement nul, vers son successeur inconditionnel
- un pointeur, éventuellement nul, vers son successeur conditionnel
- un pointeur vers le CFG qui la contient,
- une méthode de génération d'assembleur.

A.5 La classe `CFG`

... a comme attributs et méthodes

- une table des symboles, et les différentes méthodes qui y accèdent,
- une liste de `BasicBlocks`,

- un pointeur vers l'AST qu'elle implémente,
- une méthode de génération d'assembleur.

B L'ABI des PC linux de la salle 219

Compilez le programme suivant avec le vrai `gcc -S -O0` :

```
#include<inttypes.h>
void toto() {
    int64_t x=1;
    int64_t y=2;
    int64_t z=3;
    putchar('a');
}
```

Retrouvez dans le `.s` les trois constantes, le `putchar`, et enfin identifiez (en gros) son prologue et son épilogue, c'est-à-dire ce qu'il y a au début et à la fin.

Cette section vous explique tout cela, essayez de tout comprendre en détail et appelez dès que vous coincez.

Nous vous encourageons aussi à aller consulter la source, qui se trouve sur le Ternet si on cherche :

System V Application Binary Interface, AMD64 Architecture Processor Supplement

B.1 L'enregistrement d'activation

L'enregistrement d'activation, c'est la zone de mémoire dans laquelle sont allouées les variables locales à l'entrée dans une procédure/fonction.

On accède aux variables locales relativement à `%rbp`, qui est le *base pointer*. En assembleur x86, `-8(%rbp)` signifie `*(%rbp-8)` en syntaxe C. Voici à quoi ressemble la pile lors de l'exécution d'une fonction `toto` qui a trois variables locales de 64 bits et qui a été appelé par `tata` :

<code>%rsp</code> →		
	-24(%rbp)	AR of toto
	-16(%rbp)	
	-8(%rbp)	
<code>%rbp</code> →	BP of tata	
	return address	
		AR of tata
	(...)	...
	Stack bottom	...

Exercice : retrouvez sur ce dessin l'oeuvre des instructions de prologue et d'épilogue. On rappelle que l'adresse de retour de la procédure a été empilée par le `call`.

Exercice : retrouvez dans le `.s` les emplacements des variables `x`, `y` et `z`.

Une remarque : dans toute la suite du projet, les variables locales ne seront pas seulement les variables de votre programme, il y aura aussi des variables implicites créées pour recevoir les calculs intermédiaires...

B.2 Passage de paramètres

En mode 64-bits, on utilise les registres pour passer les paramètres³.

Ces registres sont spécialisés par l'ABI comme suit :

(...) the registers get assigned (in left-to-right order) for passing as follows :

3. Grosse différence avec l'ABI 32 bits, dans laquelle tous les arguments étaient passés sur la pile...

- (... for integer parameters) the next available register of the sequence `%rdi`, `%rsi`, `%rdx`, `%rcx`, `%r8` and `%r9` is used.
- Once all registers are assigned, the arguments are passed in memory. They are pushed on the stack in reversed (right-to-left) order⁴.

Dans un premier temps on pourra se limiter à des fonctions qui passent tous leurs arguments par les registres. Cela nous limite à des fonctions à 6 paramètres ou moins. Dans ce cas, produisez un message d'excuse si une fonction a plus de 6 paramètres.

La valeur de retour est passée dans `%rax`.

Remarque : en mode 32 bits les registres s'appellent `esp`, `ebp`, etc. Le "e" voulait déjà dire "extended" (to 32 bits). En mode 64 bits ils s'appellent `rsp`, `rbp`, etc. Dans les deux cas `sp` c'est *Stack Pointer*, et `bp` c'est *Base Pointer*.

B.3 Qui est propriétaire de quels registres ?

Voici la convention qui dit quels registres une fonction peut écraser, et quels registres elle est priée de laisser dans l'état où elle les a trouvés :

Registers `%rbp`, `%rbx` and `%r12` through `%r15` "belong" to the calling function and the called function is required to preserve their values. In other words, a called function must preserve these registers' values for its caller. Remaining registers "belong" to the called function. If a calling function wants to preserve such a register value across a function call, it must save the value in its local stack frame.

Le respect de cette convention est facile : il suffit de vivre uniquement avec deux registres bien choisis.

4. Right-to-left order on the stack makes the handling of functions that take a variable number of arguments (such as `printf`) simpler. The location of the first argument can always be computed statically from the stack pointer, based on the type of that argument. It would be difficult to compute the address of the first argument if the arguments were pushed in left-to-right order.